

Выводы по проделанной работе

При анализе данных вначале поработала с пропусками и заполнила их медианой (их было всего 12). Все три целевые переменные оказались сильно скошенными, тест Шапиро-Уилка подтвердил ненормальность. У IC50 среднее в пять раз больше медианы, у SI максимум 15620 при медиане 3.8. Из-за этого при обучении логарифмировала таргеты через $\log_{10}$. Удалила 18 константных признаков и признаки с взаимной корреляцией выше 0.95, в итоге осталось 159 признаков. Кластеризация показала что чётких групп в данных нет, силуэт 0.216. Выбросы не удаляла, потому что молекулы с аномально высоким SI как раз самые интересные с точки зрения фармакологии.

В регрессии сравнивала LinearRegression, Ridge, Lasso, RandomForest, GradientBoosting и XGBoost. Для лучших моделей делала GridSearchCV. По всем трём таргетам лучше всего сработал RandomForest: IC50 $R^2=0.452$, CC50 $R^2=0.433$, SI $R^2=0.346$. Тюнинг давал совсем небольшой прирост, например, по IC50 с 0.446 до 0.452. Дело не в гиперпараметрах, а в самих признаках, они слабо связаны с таргетами. Максимальная корреляция признаков с IC50 была 0.27, с SI всего 0.16. По SI попробовала косвенный подход: обучить отдельно на IC50 и CC50 и посчитать SI как отношение предсказаний. Получила $R^2=-0.007$, хуже чем просто предсказывать среднее.

В классификации переводила задачу в бинарную. Для SI дополнительно смотрела на порог 8. Везде сравнивала несколько моделей и тюнила лучшие. Лучший результат по CC50, ROC-AUC=0.883 у RandomForest. По IC50 лучший GradientBoosting с 0.792. По SI медиана RF дал 0.728. Задача SI > 8 оказалась сложнее из-за дисбаланса классов: только 36% молекул с SI > 8. Применила SMOTE на тренировочной выборке, лучший результат RF tuned 0.752. Для большой сетки параметров GradientBoosting использовала RandomizedSearchCV вместо полного перебора. Во всех задачах добавила Pipeline с VarianceThreshold и SelectKBest, который давал результат близкий к модели на полном наборе признаков. LogisticRegression во всех задачах проигрывала ансамблям, иногда была хуже случайного угадывания. Это подтверждает что данные нелинейные и линейные методы тут не подходят.

CC50 предсказывается лучше всего и в регрессии и в классификации, SI хуже всего, так как CC50 сильнее связана с молекулярным весом и размером молекулы, что хорошо отражается в дескрипторах, а SI это производная от двух других переменных с нелинейной зависимостью.